PSELDNets 评测报告 — 合成测试集 `test360_ov3`

日期：2026-10-21 · 工作目录：`/data/PSELDNets`

1. 测试设置

项目	内容
环境	conda `pseldnets`（Python 3.11，torch 2.2.1+cu121，lightning 2.2.1）
GPU	NVIDIA GeForce RTX 4090 24 GB
模型	`ckpts/mACCDOA-HTSAT-0.567.ckpt`（mACCDOA + HTS-AT，34.6 M 参数）
数据	`datasets/test360_ov3`，360 个 1 分钟片段，最大重叠数 3；切为 2160 个 10 s chunk
真值	`datasets/test360_ov3/metadata`（360 个 DCASE 格式 csv，46 132 个"类-段"track 标注）
指标	DCASE SELD：ER / F / LE / LR / SELD_scr（DOA 阈值 20°，1 s 段，macro 对 158 个出现类平均）
SED 阈值	`sed_threshold=0.5`（`configs/infer.yaml` 默认值）

推理命令（与 README Quick evaluate 一致）：

```
python src/infer.py experiment=synth_maccdoa data=synth_eval_only mode=test \
  ckpt_path=ckpts/mACCDOA-HTSAT-0.567.ckpt \
  model.kwargs.pretrained_path=null model.batch_size=8 num_workers=4 compile=false
```

- 2160 个 chunk 推理约 1 分钟，输出 360 个预测 csv。
- 两次独立运行（`21-03-18` 与 `21-48-59`）的预测文件逐字节一致 → 推理可复现。
- 模型自身 `trainer.validate`（同一数据、同一 pipeline）日志给出 macro SELD **0.601**，与下文外部评测 **0.600** 一致，说明评测链路没有对齐/版本问题。

2. 总体结果

平均方式	ER↓	F↑	LE↓	LR↑	SELD↓
macro（论文采用）	0.7793	22.07 %	20.16°	26.96 %	**0.6002**
micro	0.7793	25.37 %	19.06°	29.92 %	0.5831

误差分解（类-段级别）：Nref = 46 132，Substitution = 16 584，Deletion = 15 763，Insertion = 3 602，因此

`ER = (16584 + 15763 + 3602) / 46132 = 0.779`

检测层面（20° 匹配）：TP = 9 640，FP = 16 016，FP(空间超限) = 4 170，FN = 32 347 → **recall@20° = 22.96 %，precision@20° = 32.32 %**。

3. SED 阈值敏感性（同一模型，仅改 `sed_threshold`）

sed_threshold	ER	F(macro)	LE	LR	SELD(macro)	SELD(micro)	Insertions
0.2	1.0265	21.57 %	22.38°	34.44 %	0.6477	0.6320	18 891
0.3	0.8659	22.00 %	21.64°	31.15 %	0.6137	0.5961	9 902
0.5	**0.7793**	**22.07 %**	**20.16°**	26.96 %	**0.6002**	**0.5831**	3 602
0.7	0.7795	21.78 %	18.17°	23.11 %	0.6079	0.5943	1 421

- 阈值降到 0.2/0.3：召回上升（LR 34 %/31 %），但插入数暴涨，ER 反而恶化。
- 阈值升到 0.7：插入减少、定位误差略降，但漏检显著增加（LR 23 %）。
- **F 在所有阈值下都停在 21–22 %**：瓶颈是类别判别能力，而不是工作点选择；0.5 恰好是 ER/F/SELD 的平衡点。

4. 按房间（fold1_room1…9，每房间 40 个片段）

房间	ER	F(macro)	LE	LR	SELD(macro)
room1	0.785	30.47 %	19.45°	38.98 %	0.5496
room2	0.733	34.29 %	18.24°	41.63 %	**0.5188**（最好）
room3	0.756	30.97 %	18.44°	39.03 %	0.5396
room4	0.742	32.62 %	18.98°	40.09 %	0.5299
room5	0.798	30.50 %	17.44°	37.39 %	0.5540
room6	0.793	31.18 %	20.45°	41.11 %	0.5460
room7	0.835	20.97 %	21.03°	35.22 %	**0.5974**（最差）
room8	0.777	31.07 %	16.71°	36.38 %	0.5488
room9	0.795	25.48 %	24.11°	40.86 %	0.5664

房间间差异 0.519–0.597（约 0.08），room7 误差率最高（0.835），room9 定位误差最大（24.1°）。没有出现某个房间完全失效的情况。

5. 逐类表现（158/170 类在测试集中出现）

- 逐类 F 的中位数仅 **21.1 %**；F > 50 % 的类只有 **7** 个，F < 10 % 的类有 **41** 个。
- 高支持度（GT 段数 ⩾ 500）类的中位 F 仅 28.6 %。

类别（高支持度中最好）	nref	F	LE	LR
Drum	583	56.6 %	17.4°	69.3 %
Writing	462	50.8 %	18.5°	64.5 %
Wind	358	50.3 %	18.3°	55.7 %
Packing tape, duct tape	649	50.1 %	15.7°	55.9 %
Laughter	715	45.9 %	15.1°	61.6 %
Snare drum	634	42.6 %	20.0°	62.5 %

类别（高支持度中最差）	nref	F	LE	LR
Dishes, pots, and pans	340	1.9 %	20.5°	2.6 %
Chicken, rooster	338	2.8 %	16.2°	3.0 %
Subway, metro, underground	704	3.9 %	35.6°	7.1 %
Electric guitar	321	8.0 %	35.6°	16.5 %
Bus	338	9.5 %	18.7°	10.9 %
Tambourine	687	11.0 %	30.4°	29.3 %

规律：打击乐、人声/笑声、部分室内瞬态声（书写、胶带、火焰、咳嗽）较好；交通/城市噪声（地铁、公交、警笛）、部分乐器（电吉他、铃鼓）和餐具类明显偏弱。

6. 逐片段分布（micro SELD，360 个片段）

均值 0.583，中位数 0.591，P10 0.494，P90 0.668，最好 0.786，最差 0.362。

最差 5 个片段：`fold1_room5_mix037` (0.362)、`fold1_room1_mix037` (0.384)、`fold1_room2_mix007` (0.387)、`fold1_room8_mix005` (0.396)、`fold1_room8_mix031` (0.398)。

7. 结论与分析

1. **召回是主要瓶颈。** FN 32 347 vs TP 9 640：约 77 % 的真值 track 在段内找不到帧对齐的预测 track（LR 27 %），导致 ER 偏高、F 偏低。插入仅 3 602，说明模型"少报"而非"乱报"。

2. **定位处于阈值边缘。** 已匹配 track 的平均角误差 20.16°，且 30 % 的匹配对超过 20°（FP_spatial 4 170）。即使类别报对，方向也常落在阈值之外。
3. **阈值不是解药。** 0.2–0.7 扫描中 F 几乎不变，降低阈值只把删除换成插入；0.5 为当前最优。
4. **类别不平衡/难类明显。** 41 个类 F<10 %，集中在交通、城市噪声和部分乐器；这些类即使有 600+ 段真值也几乎检测不到。
5. **房间泛化尚可**，但 room7 的 ER 偏高，room9 的定位误差偏大，可作为后续 fine-tune 的重点。

8. 与 checkpoint 名称中 0.567 的差异

本地 0.600 与文件名 `mACCDOA-HTSAT-0.567` 相差 0.033，原因不是评测代码错误：

- 本地只有 `test360_ov3`（360 片段，最大重叠 3）。论文的 synthetic-test-set 是 **3 060 个 1 分钟片段**（`test1800_ov1` + `test900_ov2` + `test360_ov3`），0.567 应是完整测试集（或训练时验证集）上的分数，二者不可直接比较。
- 同一模型的内部验证在同一子集上给出 0.601，与本文外部评测 0.600 一致。
- 论文 Table I 中同规模模型（CNN14-Conformer + mACCDOA）在完整合成测试集上为 ER 0.805 / F 25.4 % / LE 17.3° / LR 32.1 % / SELD 0.582，量级与本文结果一致。

如需严格对齐 0.567，需要补下 `test1800_ov1`、`test900_ov2` 并在合并后的 3 060 片段上评测。

9. 发现的代码问题

`src/evaluate.py` 的逐类打印循环用 `range(args.nb_classes)`（170），但 `classwise_test_scr` 只保留 158 个"出现类"（`SELD_metrics.py` 中按 `LE==180` 删除），因此运行到第 158 行必然 `IndexError`：

```
IndexError: index 158 is out of bounds for axis 0 with size 158
```

建议改为遍历 `len(classwise_test_scr[0])`，或让 `SELD_metrics` 返回类 ID 映射后再打印。本次评测用 `_analysis/eval_analysis.py` 复刻同一套公式并保留类 ID 映射，结果与 `evaluate.py --consolidated_score` 完全一致（0.600 / 22.1 / 20.2 / 27.0）。

10. 产出文件

```
# 复现本报告（在 /data/PSELDNets 下，pseldnets 环境）
python _analysis/eval_analysis.py \
  --pred_dir logs/multi_accdoa_HTSAT_infer/runs/2026-10-21_21-48-59/submissions
```

- `_analysis/eval_analysis.py` — 评测脚本（修复逐类打印、增加逐房间/逐片段/检测统计）
- `_analysis/results.json` — 本次完整结果（含逐类、逐房间、逐片段）

- `_analysis/classwise.csv` — 158 个出现类的 ER/F/LE/LR/SELD/nref
- `_analysis/thr_0.2/`、`thr_0.3/`、`thr_0.7/` — 阈值扫描结果
- 预测：`logs/multi_accdoa_HTSAT_infer/runs/2026-10-21_21-48-59/submissions`（阈值 0.5）